

# CLASSIFICATION: LOGISTIC REGRESSION

## 1. Logistic Regression Model

Logistic distribution. Suppose  $X$  is a continuous random variable following logistic distribution. Then the distribution function and the density function take the forms as

$$F(x) = \frac{1}{1 + \exp\{-(x - \mu)/\gamma\}},$$

$$f(x) = \frac{\exp\{-(x - \mu)/\gamma\}}{\gamma\{1 + \exp(-(x - \mu)/\gamma)\}^2},$$

where  $\mu$  is a position parameter and  $\gamma > 0$  is a shape parameter.




图 1:  $F(x)$  Curve with Different  $\gamma$

Output (class label):  $Y$ .

For binary responses ( $Y \in \{0, 1\}$ ):

$$P(Y = 1|X = x) = \frac{\exp(x^\top \beta)}{1 + \exp(x^\top \beta)}.$$

Q: Could you give  $P(Y = 0|X = x)$ ?




图 2:  $f(x)$  Curve with Different  $\gamma$

Log-odds:

$$\log \left( \frac{P(Y = 1|X = x)}{P(Y = 0|X = x)} \right) = x^\top \beta. \quad (1.1)$$

Particularly, if  $x^\top \beta \rightarrow +\infty$ , then  $P(Y = 1|X = x) \rightarrow 1$ ; if  $x^\top \beta \rightarrow -\infty$ , then  $P(Y = 1|X = x) \rightarrow 0$ .

## 2. Model Estimation

Suppose for the  $i$ th subject we observe  $x_i$  and  $y_i$ . Let  $p(x_i; \beta) = P(Y = 1|X = x_i)$ .

Maximum likelihood estimation:

$$\ell(\beta) = \sum_{i=1}^N \left\{ y_i \log p(x_i; \beta) + (1 - y_i) \log(1 - p(x_i; \beta)) \right\}$$

Q: derive the blue part by yourself.

To maximize the log-likelihood, we set its derivatives to zero. The score equations are

$$\frac{\partial \ell(\beta)}{\partial \beta} = ??? = 0$$

Optimization: Newton-Raphson algorithm

$$\beta^{new} = \beta^{old} - \left( \frac{\partial^2 \ell(\beta)}{\partial \beta \partial \beta^\top} \right)^{-1} \frac{\partial \ell(\beta)}{\partial \beta}.$$

where

$$\frac{\partial^2 \ell(\beta)}{\partial \beta \partial \beta^\top} = ??? \quad (2.1)$$

Define  $\mathbf{W}$  as a  $N \times N$  diagonal matrix of weights with the  $i$ th diagonal element  $p(x_i; \beta^{old})(1 - p(x_i; \beta^{old}))$  and  $\mathbf{p} = (p(x_1; \beta), \dots, p(x_N; \beta))^\top$ . Then we have,

$$\begin{aligned} \frac{\partial \ell(\beta)}{\partial \beta} &= ??? \\ \frac{\partial^2 \ell(\beta)}{\partial \beta \partial \beta^\top} &= ??? \end{aligned}$$

Then the Newton step is

$$\beta^{new} = \beta^{old} + ???$$

This algorithm is then referred to as *iteratively reweighted least squares*.

Question\*: Write Newton-Raphson algorithm to estimate logistic regression by yourself.

Generate  $X = (1, X_1, X_2)$ , where  $X_j \sim N(0, I_N)$ .

Set true parameter  $\beta = (0.5, 1.2, -1)^\top$ .

Set  $N = 200, 500, 800, 1000$ .

Estimate  $\beta$  using NR algorithm for  $R = 200$  times. For each  $j$ , draw  $(\hat{\beta}_j^{(r)} - \beta_j)$  in boxplot for  $N = 200, 500, 800, 1000$ . Submit your code (with detailed comments) + report your plot & findings in pdf.

Other algorithms can be found in the 附录 A & B 《统计机器学习》。

Comment:

(1)  $\hat{\beta}$  converge in distribution to  $N(\beta, (\mathbf{X}^\top \mathbf{W} \mathbf{X})^{-1})$ . The inference can be done.

(2) Likelihood Ratio Test:

$$\begin{aligned} LR &= -2 \max_{\beta_0} \ell(\beta_0, \beta_1 = 0) + 2 \max_{\beta_0, \beta_1} \ell(\beta_0, \beta_1) \\ &= DEV_0 - DEV_1 \end{aligned}$$

LR asymptotically ( $N$  is large enough) follows Chi-square distribution with degree of freedoms  $p_0$ , where  $p_0$  is number of parameters in  $\beta_1$ .

### 3. Multi-nominal Logistic Regression Model

If  $Y \in \{1, \dots, K\}$ , then the multi-nominal logistic regression model takes the form,

$$P(Y = k | X = x) = \frac{\exp(\beta_k^\top x)}{1 + \sum_{k=1}^{K-1} \exp(\beta_k^\top x)}, \quad k = 1, 2, \dots, K-1. \quad (3.1)$$

### 4. Model Evaluation

		Predicted class		
		<i>yes</i>	<i>no</i>	Total
Actual class	<i>yes</i>	<i>TP</i>	<i>FN</i>	<i>P</i>
	<i>no</i>	<i>FP</i>	<i>TN</i>	<i>N</i>
Total		<i>P'</i>	<i>N'</i>	<i>P + N</i>

图 3: Classification evaluation: Confusion matrix.

#### 1. 总体衡量

(1) Accuracy (精度):

$$\frac{TP + TN}{P + N}$$

(2) Error rate (错分率):

$$\frac{FP + FN}{P + N}.$$

#### 2. 查准率、查全率与 F1

Measure	Formula
accuracy, recognition rate	$\frac{TP+TN}{P+N}$
error rate, misclassification rate	$\frac{FP+FN}{P+N}$
sensitivity, true positive rate, recall	$\frac{TP}{P}$
specificity, true negative rate	$\frac{TN}{N}$
precision	$\frac{TP}{TP+FP}$
$F, F_1, F\text{-score},$ harmonic mean of precision and recall	$\frac{2 \times \text{precision} \times \text{recall}}{\text{precision} + \text{recall}}$
$F_\beta$ , where $\beta$ is a non-negative real number	$\frac{(1 + \beta^2) \times \text{precision} \times \text{recall}}{\beta^2 \times \text{precision} + \text{recall}}$

图 4: Evaluation measures.

在“抓坏蛋”的分类任务中，我们更关心“预测的坏蛋是否是真的坏蛋”，以及“有多少坏蛋被挑出来了”；而不在乎“是否把好人预测成了好人”。这种情况下，precision（查准率）和 recall（查全率）更能代表这类需求的性能度量。它们定义如下：

$$\text{precision} = \frac{TP}{TP + FP},$$

$$\text{recall} = \frac{TP}{TP + FN}.$$

这里涉及阈值选择，一般阈值越高，则查准率高；阈值越低，查全率高。

F1 度量 (precision 和 recall 的调和平均)：

$$F1 = \frac{2 \times P \times R}{P + R}$$

有时候 precision 和 recall 的重要程度不同。比如，在癌症筛查中，可以允许误诊，但是希望能够尽量准确查出癌症，此时，查全率更重要；在一些营销场景中，由于每一次营销都要付出成本，因此希望查准率更高。 $F_\beta$  度量：

$$F_\beta = \frac{(1 + \beta^2) \times P \times R}{(\beta^2 \times P) + R} \quad (4.1)$$

$F_\beta$  是加权调和平均:

$$\frac{1}{F_\beta} = \frac{1}{1 + \beta^2} \left( \frac{1}{P} + \frac{\beta^2}{R} \right) \quad (4.2)$$

### 3. ROC 曲线及 AUC

之前叙述的方法依赖于阈值 (threshold) 的设定, 因此, 阈值设置的好坏往往影响评估度量的差异。这显然是不合理的。

事实上, 根据预测概率, 我们可以对样本进行排序。直观上, 如果一个分类器, 能够尽量多的把正样本排序在负样本之前, 那么这个分类器具有很好的分类能力。这个排序情况与阈值的设置无关。ROC 曲线正是从这个角度出发设计的。

ROC 全称是 (Receiver Operating Characteristic) [受试者工作特征曲线]。这个名字很怪, 跟它历史有关: ROC 是由二战中的电子工程师和雷达工程师发明的, 用来侦测战场上的敌军载具 (飞机、船舰), 也就是信号检测理论。

ROC 曲线的横轴是“假正例率” (False Positive Rate, FPR), 纵轴是“真正例率” (True Positive Rate, TPR)。

$$TPR = \frac{TP}{TP + FN}, \quad FPR = \frac{FP}{TN + FP}.$$

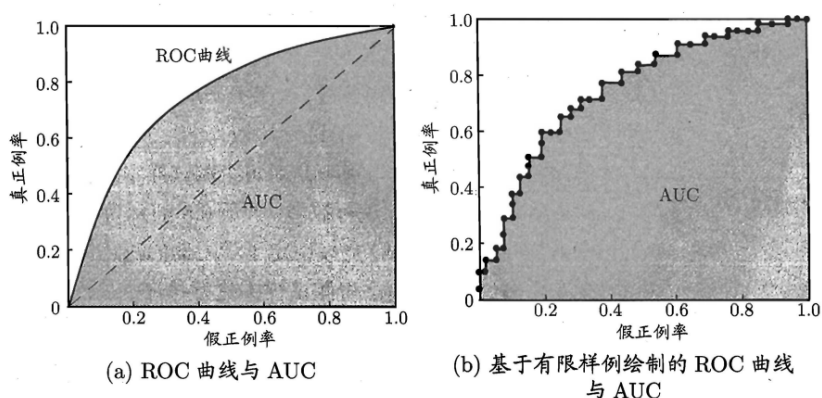


图 2.4 ROC 曲线与 AUC 示意图

图 5: ROC 和 AUC.

一般采用采取 ROC 曲线下的面积 AUC (Area Under Curve) 来判断分类器性能的优劣。

AUC 取值只与排序有关。假设有  $m^+$  个正例和  $m^-$  个负例，令  $D^+$  与  $D^-$  分别表示正例、反例集合。定义排序“损失”如下：

$$\ell_{rank} = \frac{1}{m^+m^-} \sum_{x^+ \in D^+} \sum_{x^- \in D^-} \left( I(f(x^+) < f(x^-)) + \frac{1}{2} I(f(x^+) = f(x^-)) \right) \quad (4.3)$$

理解：若正例的预测值小于反例，则记一个“罚分”，若相等，则记 0.5 个罚分。

$$AUC = 1 - \ell_{rank}. \quad (4.4)$$

### 3. 成本收益曲线

成本的度量（覆盖率）：

$$\frac{TP + FP}{P + N}.$$

收益的度量（捕获率）：Recall(也就是查全率)




图 6: 成本收益曲线.

### 4. 多次度量

由于每次抽样时测试集存在随机性，一般重复  $K$  次试验后取平均值作为度量。

## 5. 类别不均衡

1. 设置阈值  $\frac{p_i}{1-p_i} > \frac{m^+}{m^-}$ , 则预测为正例 (不再使用 1 作为 cutoff)
2. 过采样 (Oversampling): 例如: SMOTE 算法, 对正例  $x$  进行插值产生新正例
3. 欠采样 (Undersampling): 例如: EasyEnsemble 算法, 将反例划分为几个子集, 分别学习, 在利用集成学习的方式汇总结果。

## 6. 广义线性模型

### 1. 指数分布族

$$f(y|\theta, \psi) = \exp \left\{ \frac{yb(\theta) - c(\theta)}{a(\psi)} + d(y, \psi) \right\}.$$

$\theta$ : 典型参数, 与  $y$  的均值  $\mu$  有关

$\psi$ : 刻度参数, 与方差有关

举例: 正态分布

$$f(y|\mu, \sigma^2) = \frac{1}{\sqrt{2\pi}\sigma} \exp \left\{ -\frac{(y - \mu)^2}{2\sigma^2} \right\}$$

泊松分布:

$$f(y|\mu) = \frac{\exp(-\mu)\mu^y}{y!}$$

### 2. 广义线性模型 (Generalized Linear Model)

(1) 因变量  $y$  的分布为指数族分布, 均值为  $\mu$

(2) 系统成分:  $\eta = x^\top \beta$ .

(3) 链接函数:  $g(\mu) = x^\top \beta$ , 其中  $g(\cdot)$  为一对一、连续可导的变换。

对于逻辑回归 (二项分布  $n = 1$ ): logit 链接函数

$$x^\top \beta = \log \left( \frac{\mu}{1 - \mu} \right) \quad (6.1)$$

对于计数变量: 对数链接函数:  $\log(\mu) = x^\top \beta$ .